코로나 확산속도 예측

COVID-19 dataset

코로나의 확산속도 예측

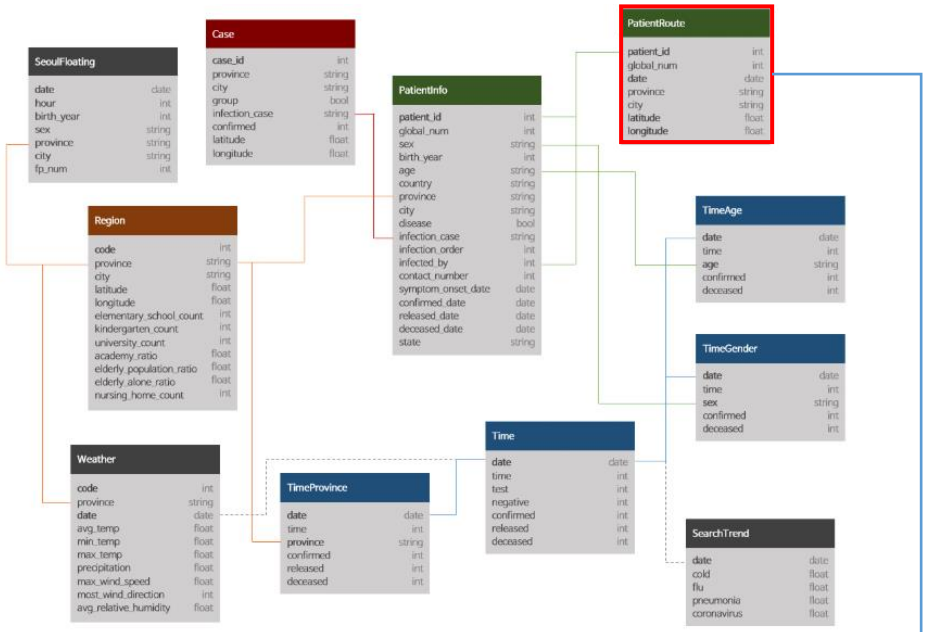

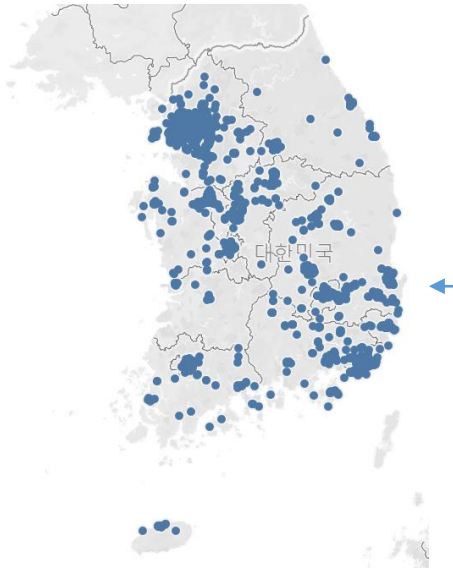

	patient_id	global_num	date	province	city	type	latitude	longitude
0	1000000001	2.0	2020-01-22	Gyeonggi-do	Gimpo-si	airport	37.615246	126.715632
1	1000000001	2.0	2020-01-24	Seoul	Jung-gu	hospital	37.567241	127.005659
2	1000000002	5.0	2020-01-25	Seoul	Seongbuk-gu	etc	37.592560	127.017048
3	1000000002	5.0	2020-01-26	Seoul	Seongbuk-gu	store	37.591810	127.016822
4	1000000002	5.0	2020-01-26	Seoul	Seongdong-gu	public_transportation	37.563992	127.029534

https://www.kaggle.com/kimjihoo/coronavirusdataset

EDA

일부 확진자의 경로

가설

확진자의 경로가 시작점에서부터 거리가 멀수록,

코로나 확산에 더 큰 영향을 줬을 것이다.

Formulation

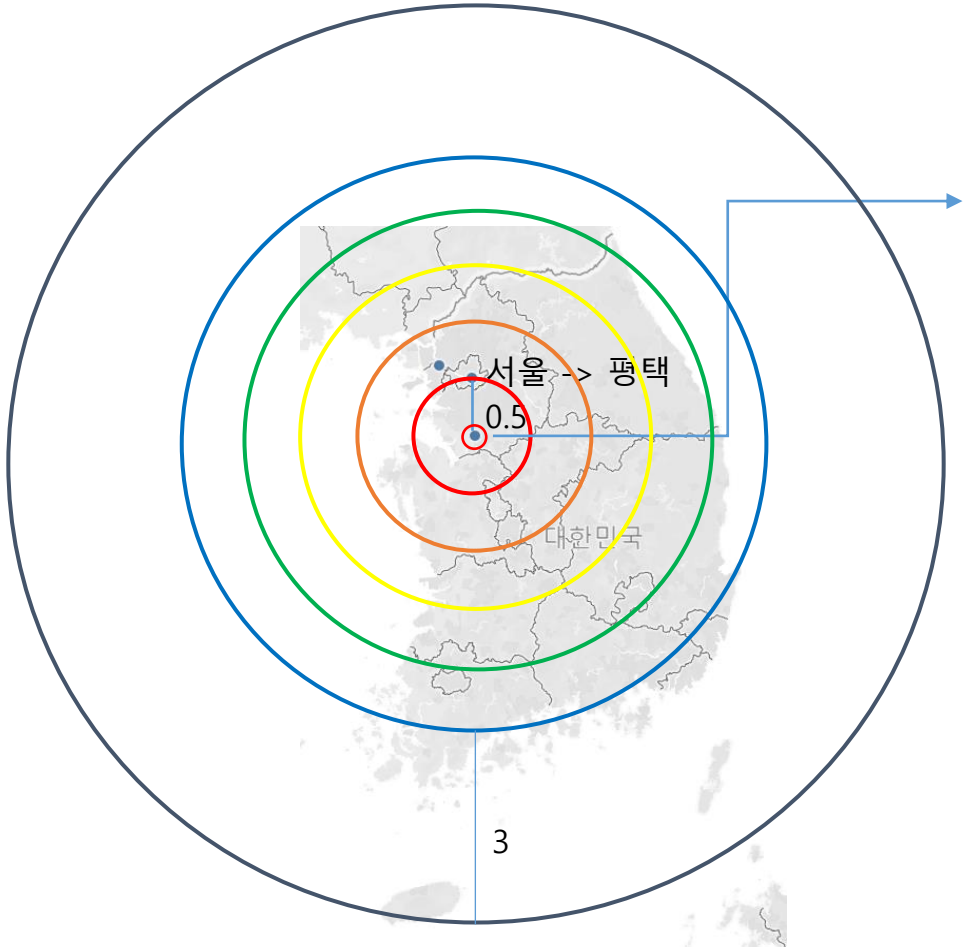

원은 위도와 경도를 기준으로 설정한 크기다.

서울에서 경기도(평택)까지의 차이: 위도: 0.5

0.5를 반지름으로 해서 원을 하나씩 만들고 추가시킴

원안에 확진자의 특정 경로가 있으면 원의 weight를 경로에 줌

Formulation

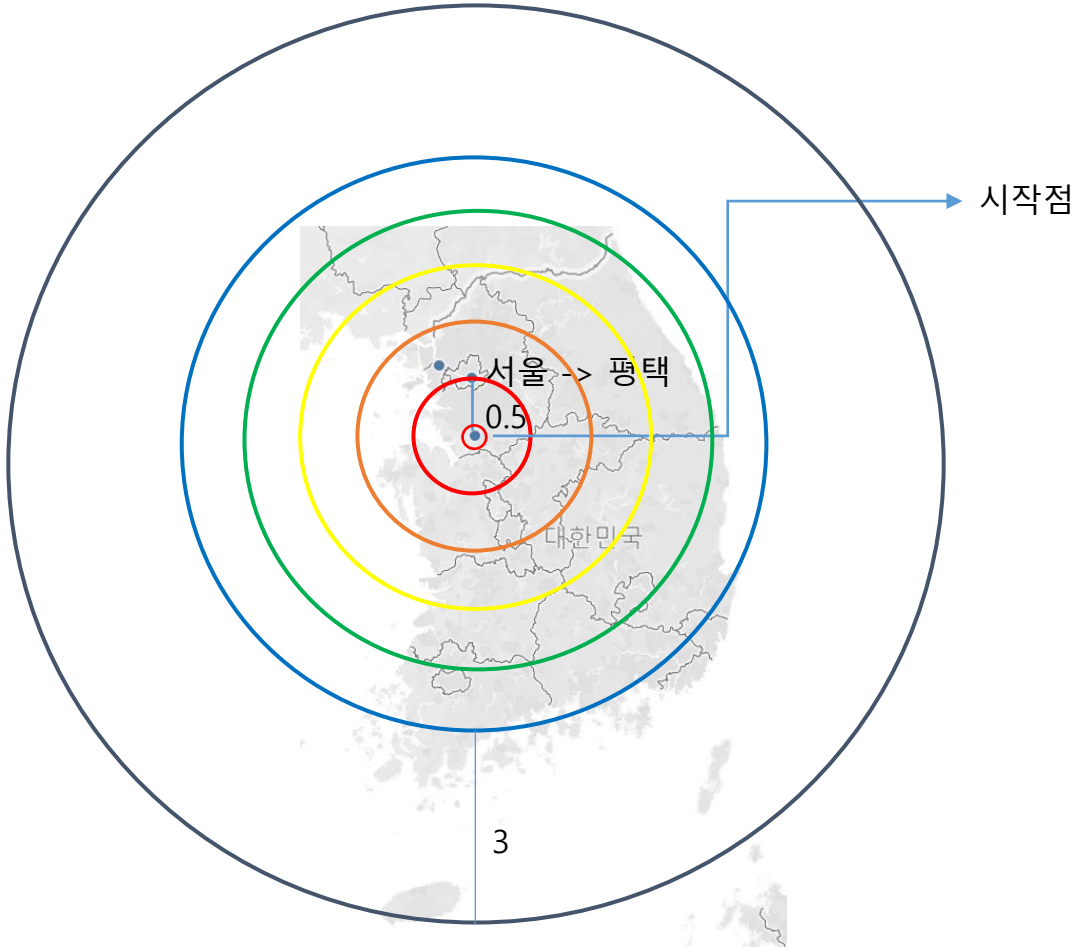

원은 위도와 경도를 기준으로 설정한 크기다.

$$\text{Diffusion rate (확산속도)} = \sum_{1}^{\text{days}} (w_{CN} + x_i)$$

w_{CN}: 특정 원에 해당하는 weight값 ⟶ 하이퍼파라미터

CN: Cluster Number

x_i: 확진자가 지나간 경로

$days$: 일 단위 ⟶ 하이퍼파라미터

Clustering

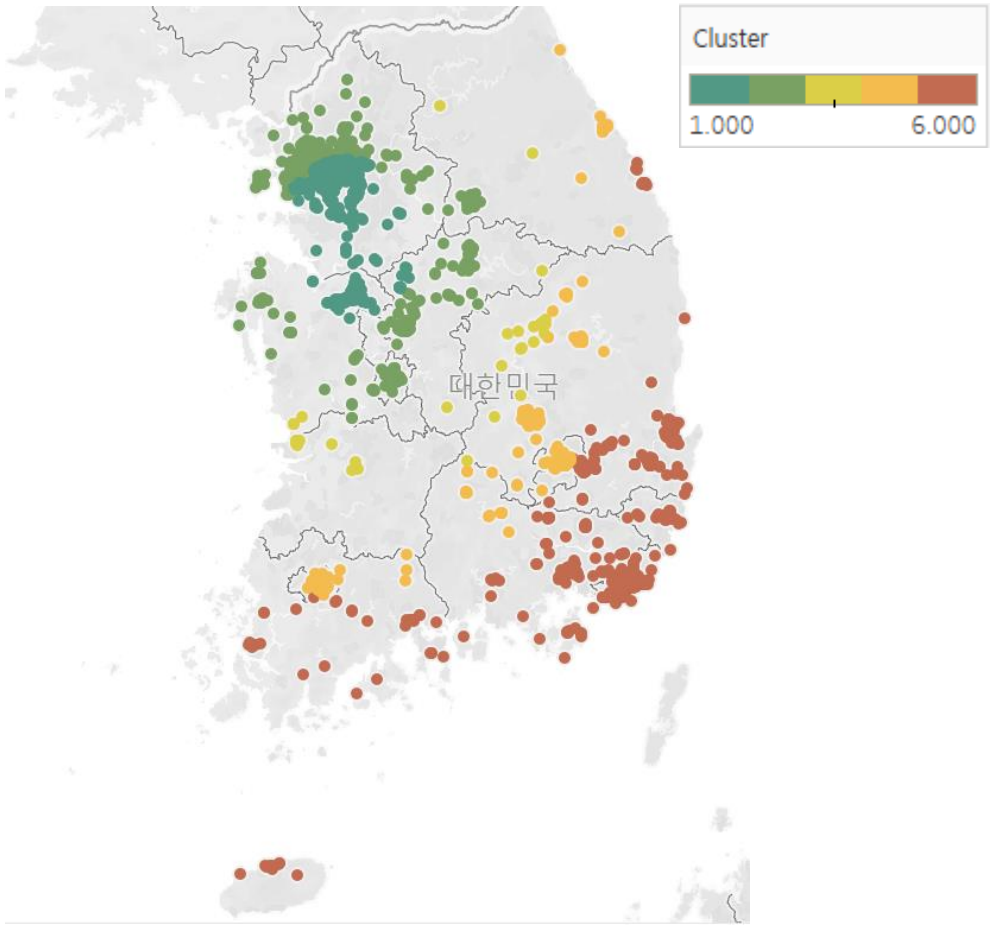

ED: Euclidean Distance

Cluster1: ED <= 0.5

Cluster2: 0.5 < ED <= 1.0

Cluster3: 1.0 < ED <= 1.5

Cluster4: 1.5 < ED <= 2.0

Cluster5: 2.0 < ED <= 2.5

Cluster6: ED > 2.5

Weight per cluster

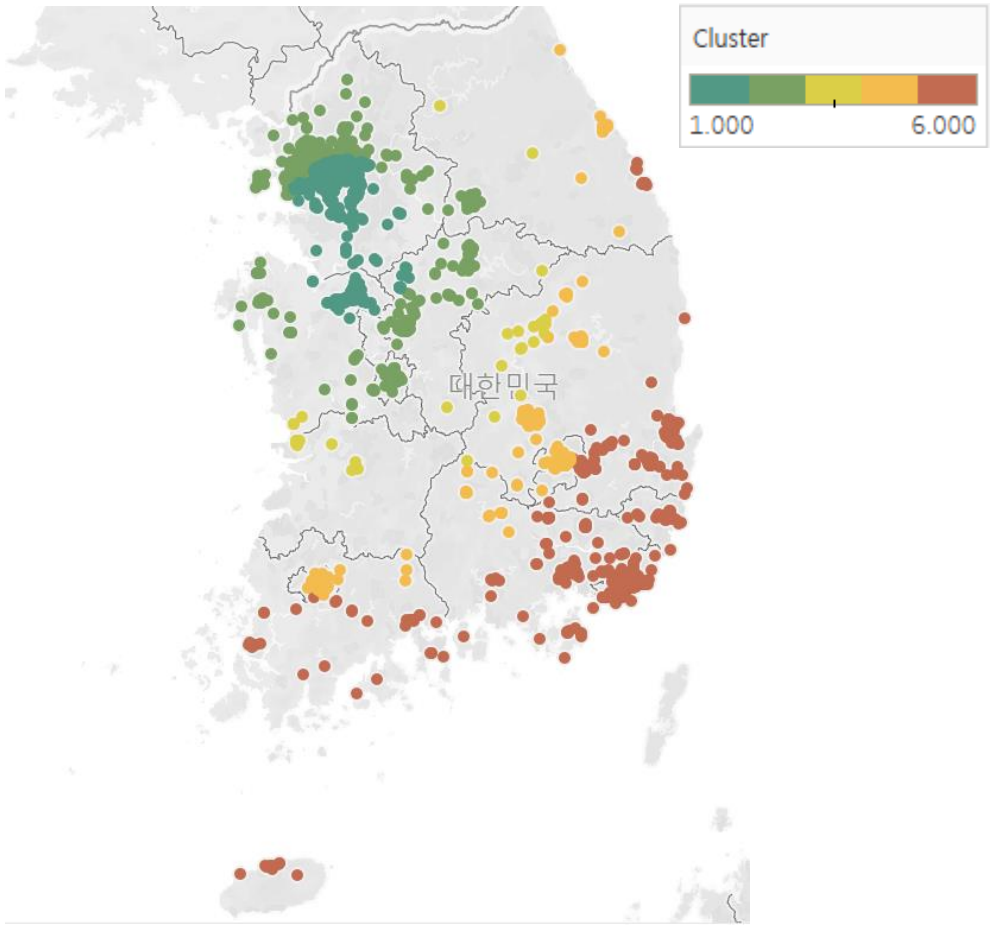

하이퍼파라미터

$$w_{CN} = 0.1 + CN$$

CN: Cluster Number

Cluster1: 0.1의 weight

Cluster2: 0.12의 weight

Cluster3: 0.14의 weight

Cluster4: 0.16의 weight

Cluster5: 0.18의 weight

Cluster6: 0.2의 weight

Diffusion rate

코로나 확산속도

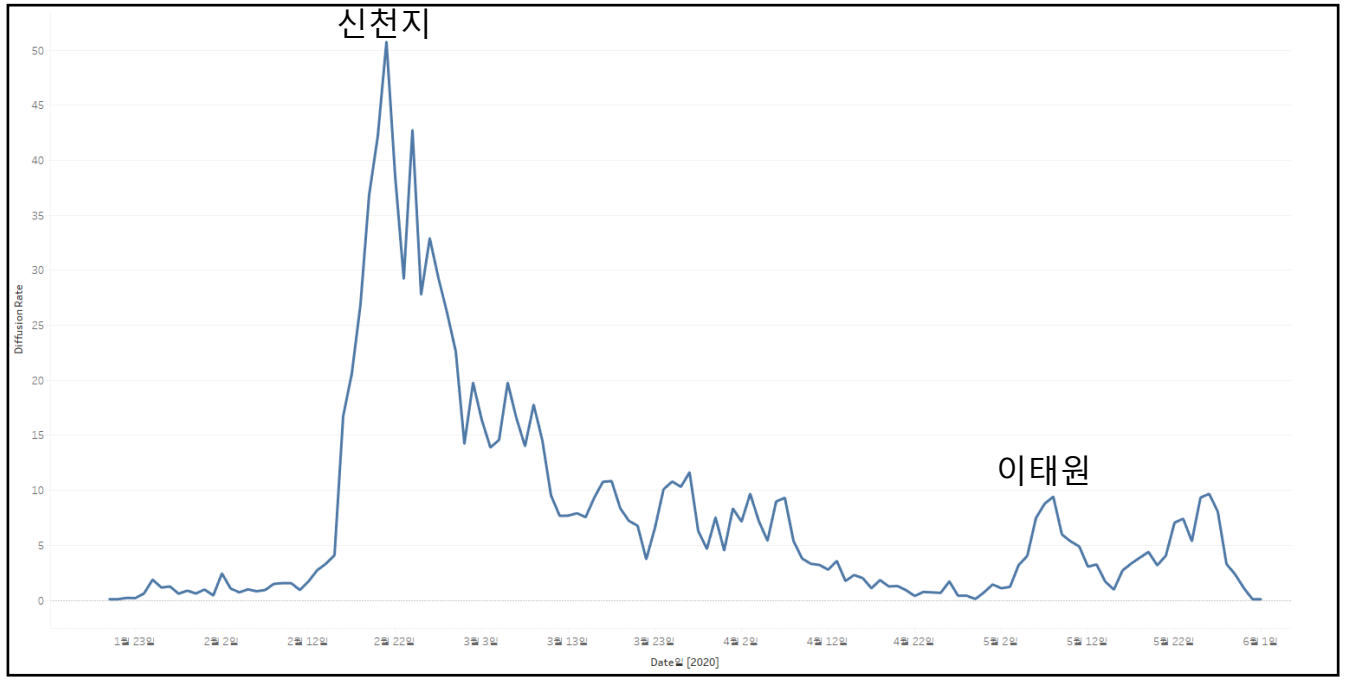

처음에 잠잠했다가 신천지 땜에 한번 확산속도가 크게 커지고
다시 잠잠해졌다가 이태원, 콜센터 등으로 인해 확산속도가 오르락 내리락 하는걸 볼 수 있음

ARIMA 분석(시계열자료 특성 분석)

시계열 요소분해 시각화

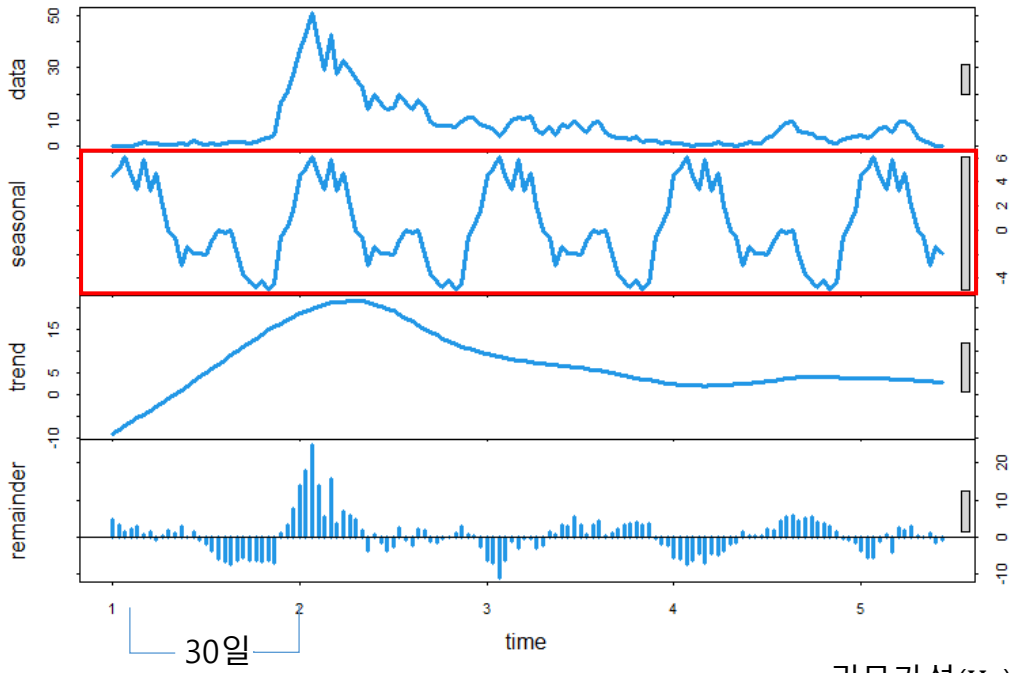

데이터가 계절성을 띤다 ⟶ 계절 차분을 적용

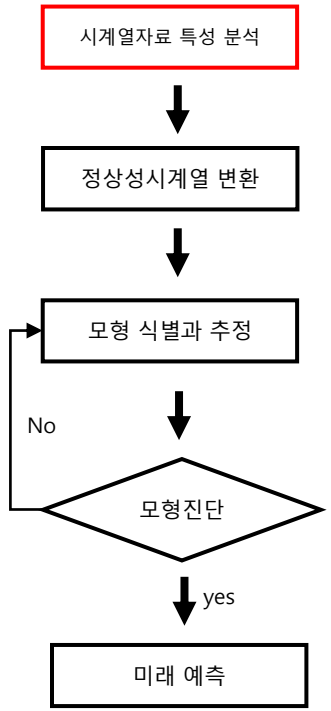

Augmented Dickey-Fuller Test

귀무가설(H_0): 시계열 데이터가 비정상성이다. ✓
대립가설(H_1): 시계열 데이터가 정상성을 만족한다.

```
data:  tsdata[, 2]
Dickey-Fuller = -3.0558, Lag order = 5, p-value = 0.1374
alternative hypothesis: stationary
```

⟶ 현 데이터는 비정상성 데이터다.

ARIMA 분석(정상성시계열 변환)

특정 패턴이 보이는 계절성 제거

차분을 통해 비정상성시계열 자료를 정상성시계열로 변환

차분: 현재 시점에서 이전 시점의 자료를 빼는 연산

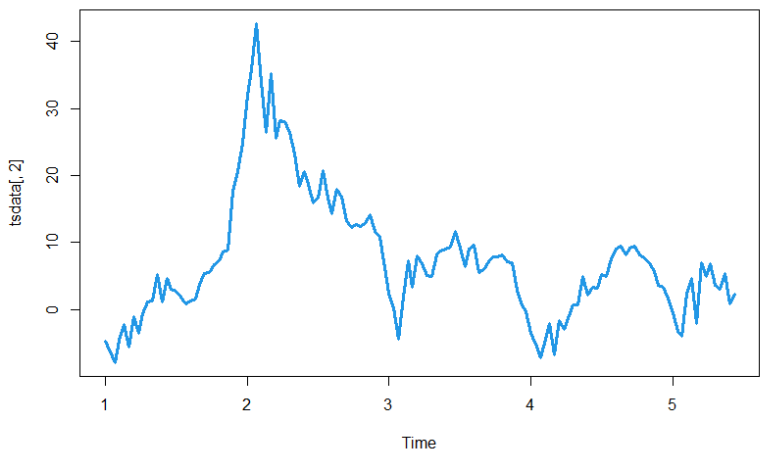

계절성 제거

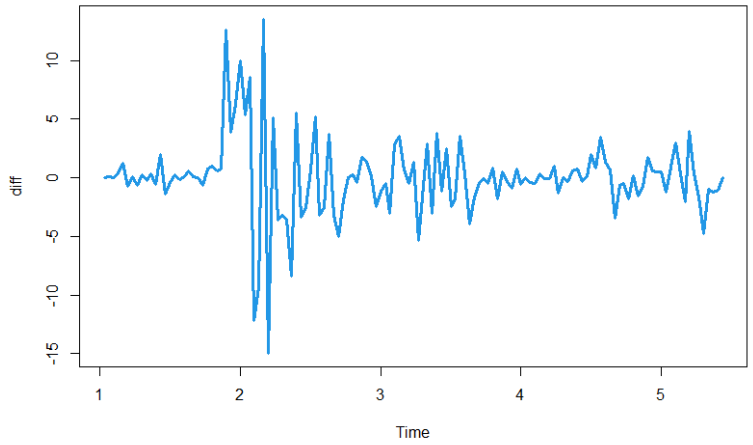

차분

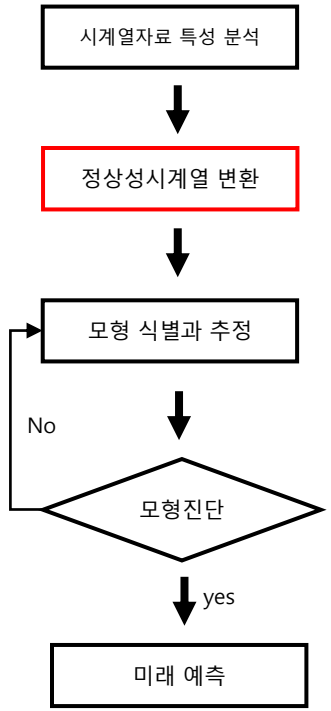

ARIMA 분석(모형 식별과 추정)

AR모형의 차수: 4
차분 치수: 0
MA모형의 차수: 1

계절성을 갖는 MA모형 차수: 1

계절의 차수: 30일

```
Series: diff[, 2]
ARIMA(4,0,1)(0,0,1)[30] with zero mean

Coefficients:
          ar1      ar2     ar3     ar4     ma1     sma1
      -1.0548  -0.0857  0.3082  0.0929  0.8525  0.1484
s.e.   0.1664   0.1310  0.1274  0.1162  0.1355  0.0785
```

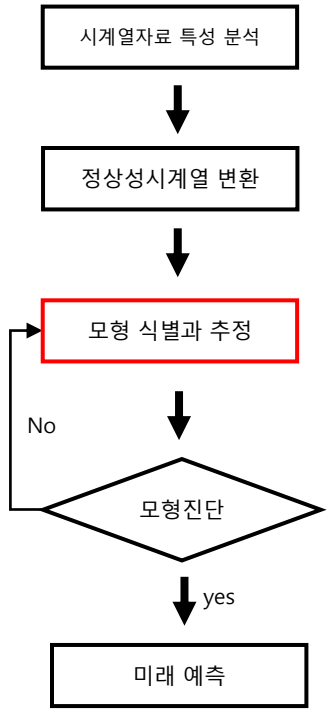

차수: 시간 지연 수
AR(자기상관성)모형
MA(이동평균)모형

ARIMA 분석(모형 진단)

모형의 적합성 검정

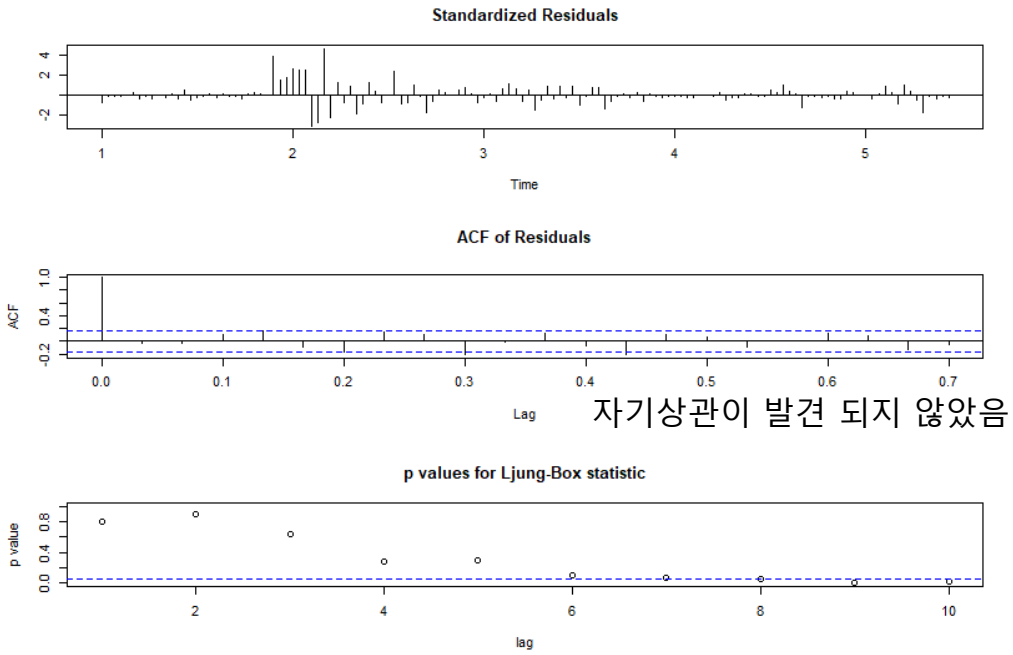

자기상관이 발견 되지 않았음

```
        Box-Ljung test

data:  arima_md$residuals
X-squared = 0.063959, df = 1, p-value = 0.8003
```

모형의 잔차가 불규칙하고 독립적으로 분포되어 있다.

통계적으로 적절한 모형이다

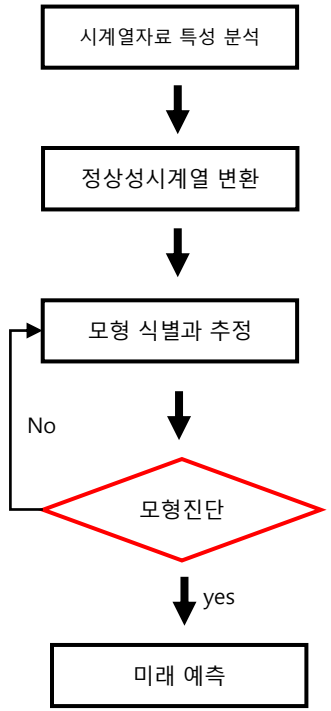

자기상관: 이전의 값이 이후의 값에 영향을 미치고 있는 상황

ARIMA 분석(미래 예측)

30일 예측

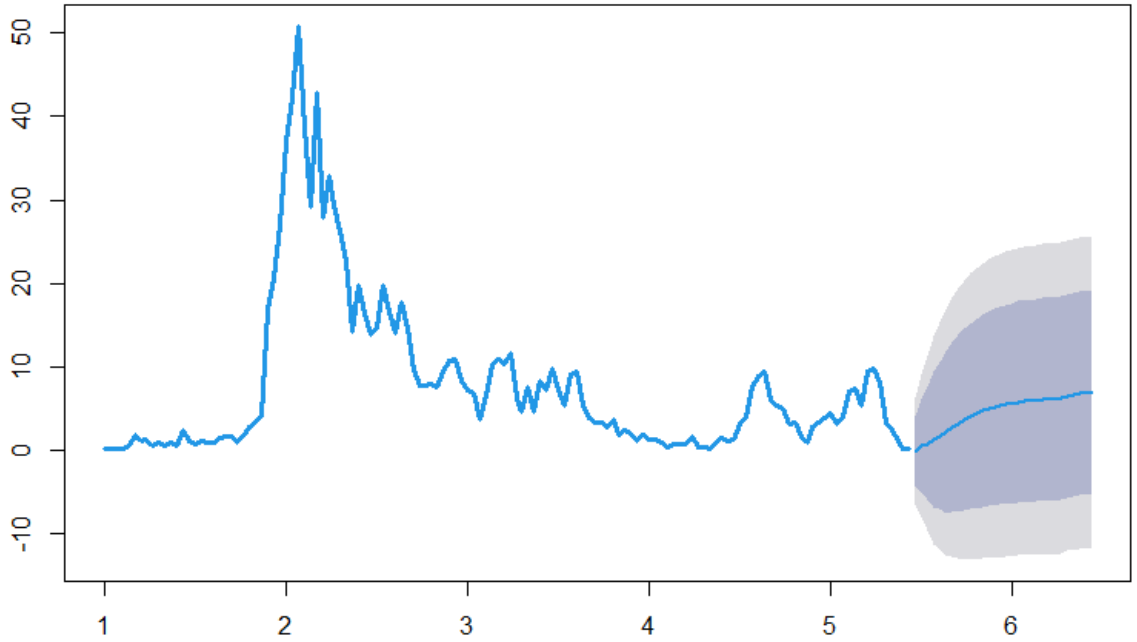

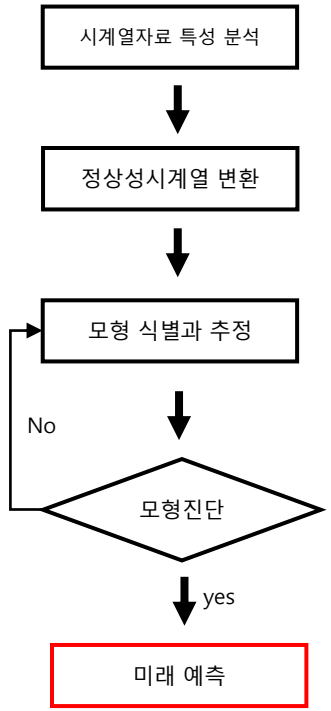

코로나의 확산속도는 다시 증가하는 추세를 보인다.

결론 및 향후 방향

결론

확산속도가 다시 증가하고 있는 추세다.

향후방향

Clustering과 하이퍼파라미터를 이용해서 weight를 할당했는데, 더 최적화된 값이 필요

인구밀도와 지역 별 거리가 반비례 관계를 가져서 formulation한 식에 weight를 반영하지 않았는데, 인구밀도를 이용해서 식을 update하는 방안 고려

Thank You